

GÊMEO DIGITAL HÍBRIDO PARA DETECCÃO E DIAGNÓSTICO DE FALHAS POR SOMBREAMENTO PARCIAL EM SISTEMAS FOTOVOLTAICOS

Ernesto Manuel Distinto Ufuene

Orientador: Prof. Dr. Sergio Takeo Kofuji

*Programa de Pós-Graduação em Engenharia Elétrica
Escola Politécnica da Universidade de São Paulo
Área de Sistemas Eletrônicos*

19 de Novembro de 2025



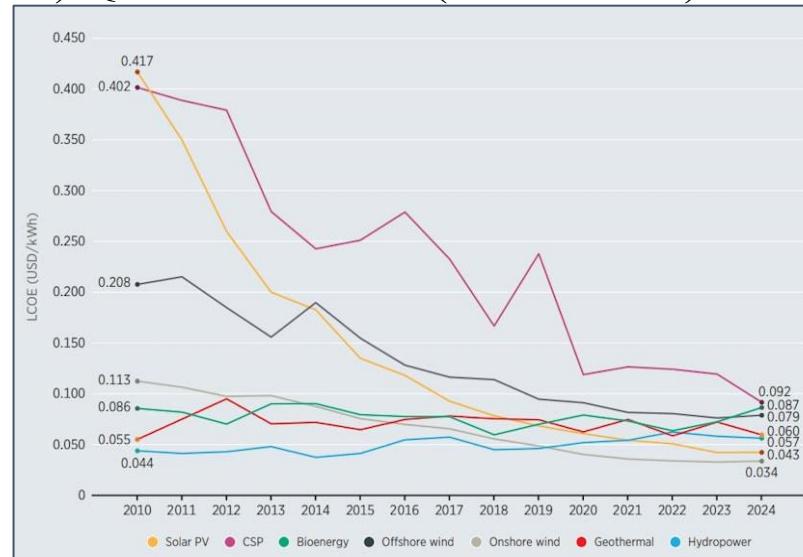
Uma jornada rumo a um Gêmeo Digital Híbrido para sistemas fotovoltaicos inteligentes!

1. Introdução

1.1 Contexto

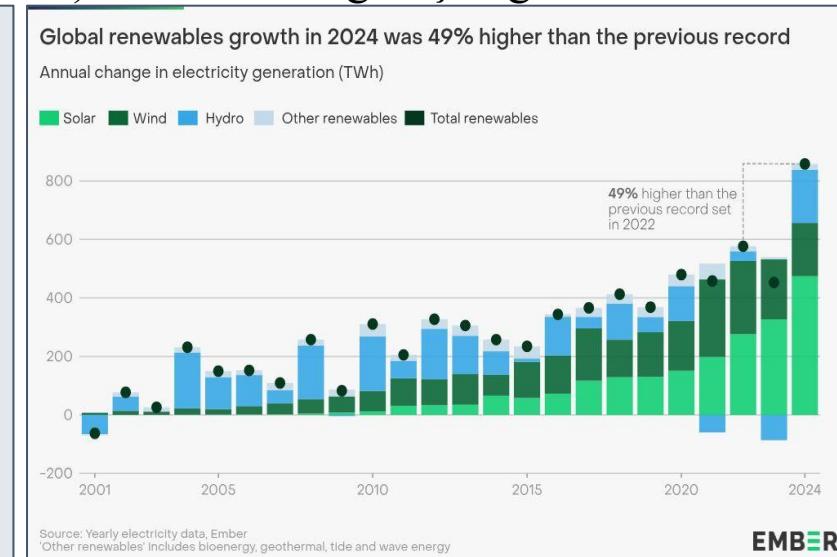
1. A energia solar fotovoltaica é a fonte que mais cresce na matriz elétrica global.
2. Com destaque da **microgeração e geração distribuída (GD)**
3. Com esse crescimento, o desafios deixa de ser apenas os custos e passa a ser a **confiabilidade e a operação a longo prazo**.
4. Um dos **fatores que afeta a confiabilidade e a operação a longo prazo** desses sistemas é um fenómeno conhecido como **sombreamento parcial**.

a) Queda nos custos (2010 a 2024) PV



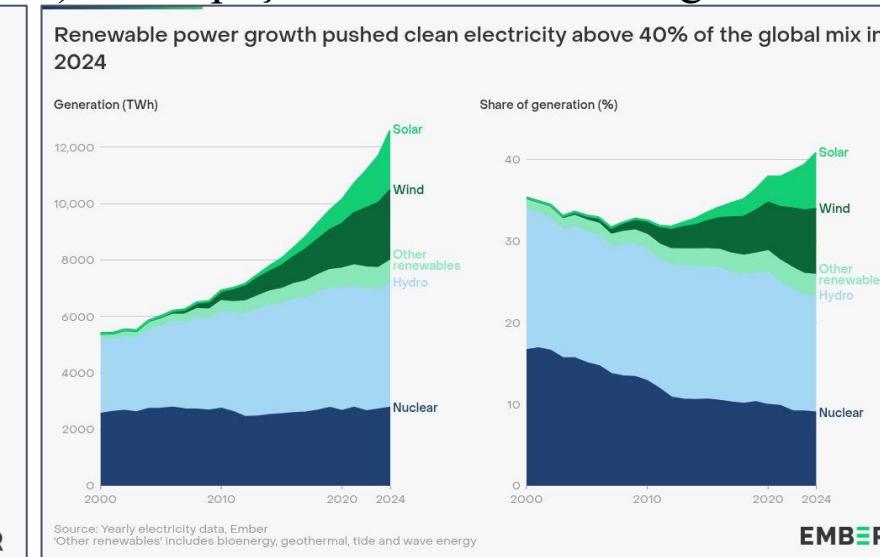
Fonte: IRENA (2025)

b) Aumento da geração global PV



Fonte: Ember (2025)

c) Participação na matriz elétrica global PV



Fonte: Ember (2025)

O FV se tornou popular e acessível. Novas soluções de gestão e operação, inteligentes e acessíveis, são necessárias



1. Introdução

1.2 Problema: O Sombreamento Parcial

Distribuição **não uniforme** da irradiância no módulo, provocado por (obstáculos temporários ou permanentes, como edifícios, árvores, antenas, chaminés, sujeira acumulada ou detritos), que induzir polarização reversa nas células sombreadas.

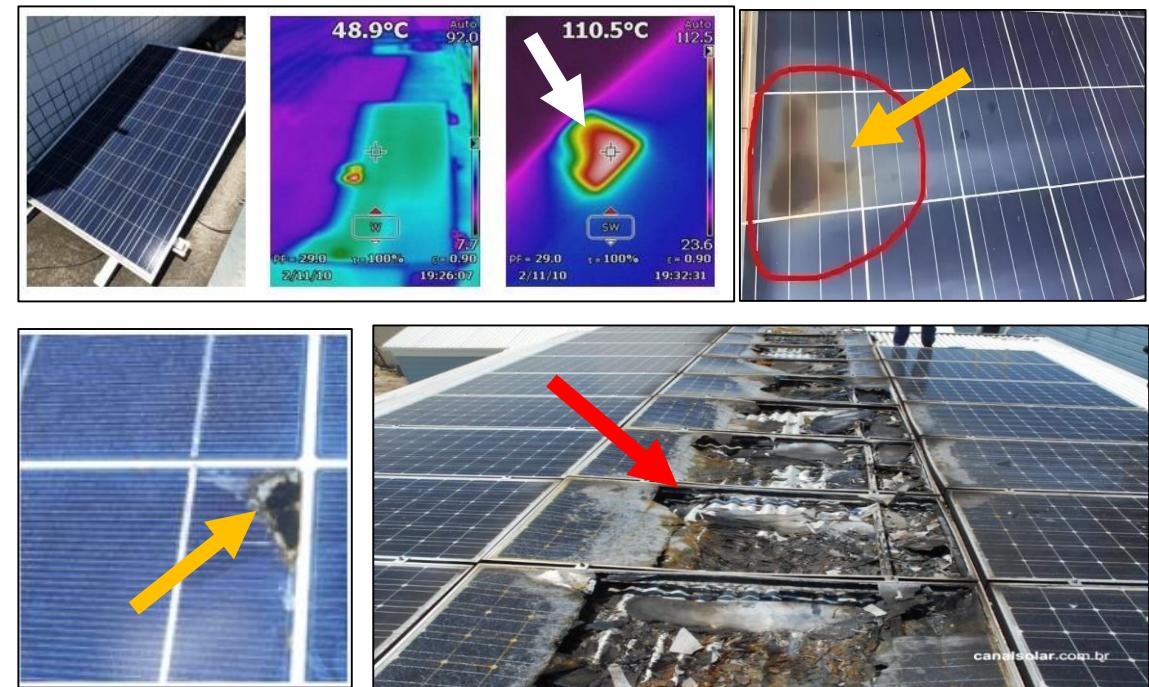


Fonte: (Como Evitar o Sombreamento No Painel Solar?, n.d.; O Sombreamento Em Energia Solar e Suas Consequências, n.d.; Redução Do Efeito Das Sombras Nos Módulos, n.d.; Saiba Como Minimizar o Efeito Da Sombra Nos Sistemas Fotovoltaicos, n.d.)

O sombreamento parcial é um mecanismo ativo de degradação que compromete a segurança e a vida útil do sistema.

Causando:

Degradação Acelerada (2) - Queima (em casos mais graves)

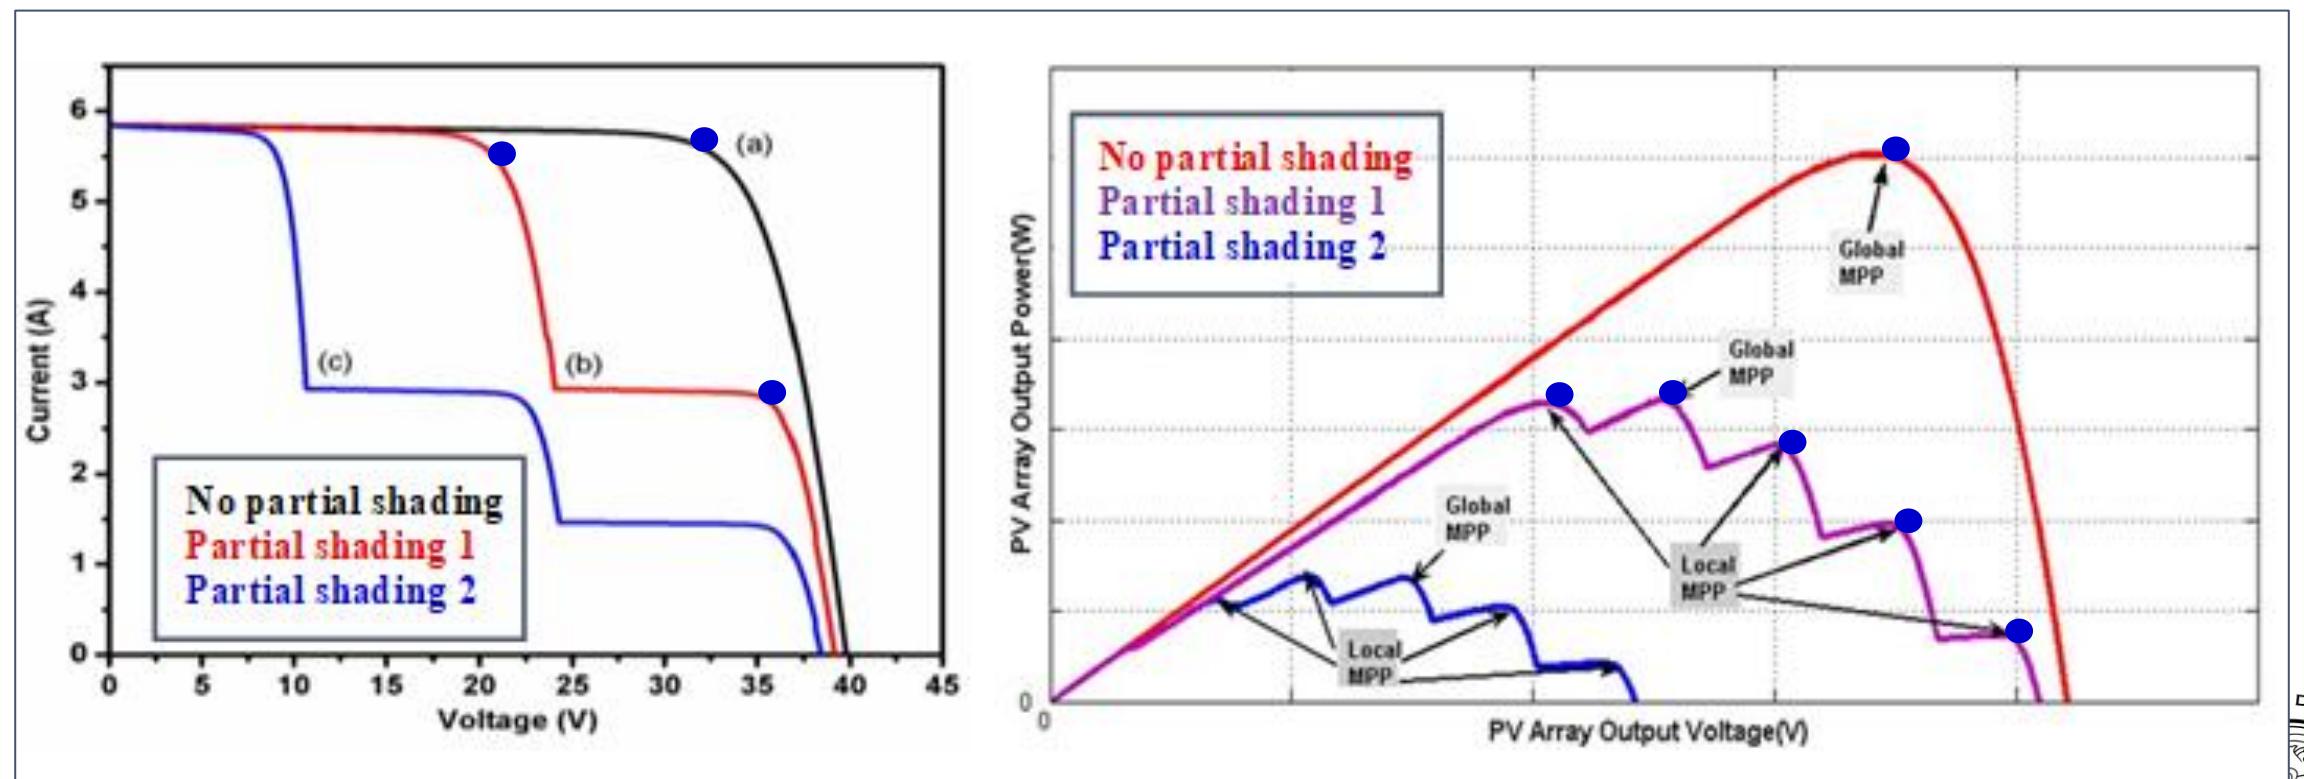


Fonte: (Causas e Efeitos Da Corrente Reversa Nos Módulos Fotovoltaicos, n.d.; Entenda Os Principais Danos Nos Módulos Fotovoltaicos, n.d.; In Che Modo i Punti Caldi Possono Influenzare i Pannelli..., n.d.; Redução Do Efeito Das Sombras Nos Módulos, n.d.)

1.2 Problema: O Sombreamento Parcial (2)

Para além dos danos físicos, o sombreamento parcial é também responsável de: **Perdas de Potência:** Ativação de díodos de bypass, múltiplos picos na curva P-V que podem **confundir os controladores MPPT**.

A assinatura do sombreamento parcial: múltiplos picos de potência e queda drástica de performance do sistema.



Fonte: autor, adaptada de (Saleem et al., 2020)

Nossa solução visa detectar em tempo real essa 'assinatura'.

1.3 hipótese

Gêmeos Digitais Híbridos (GDH) que integram modelos baseados em física e modelos baseados em dados podem detectar Condição de Sombreamento Parcial (Partial Shading Condition - PSC) em tempo real com boa precisão.



1.4 Objetivos

1.4.1 Objetivo Geral

Desenvolver e validar **experimentalmente** um **gêmeo digital híbrido (GDH)** que integra **modelos** baseados em **física** e **modelos** orientados por **dados** em uma plataforma embarcada de baixo custo, utilizando sensores e conectividade IoT para detecção em tempo real de PSC em sistemas fotovoltaicos de pequeno porte.



1.4 Objectivos (2)

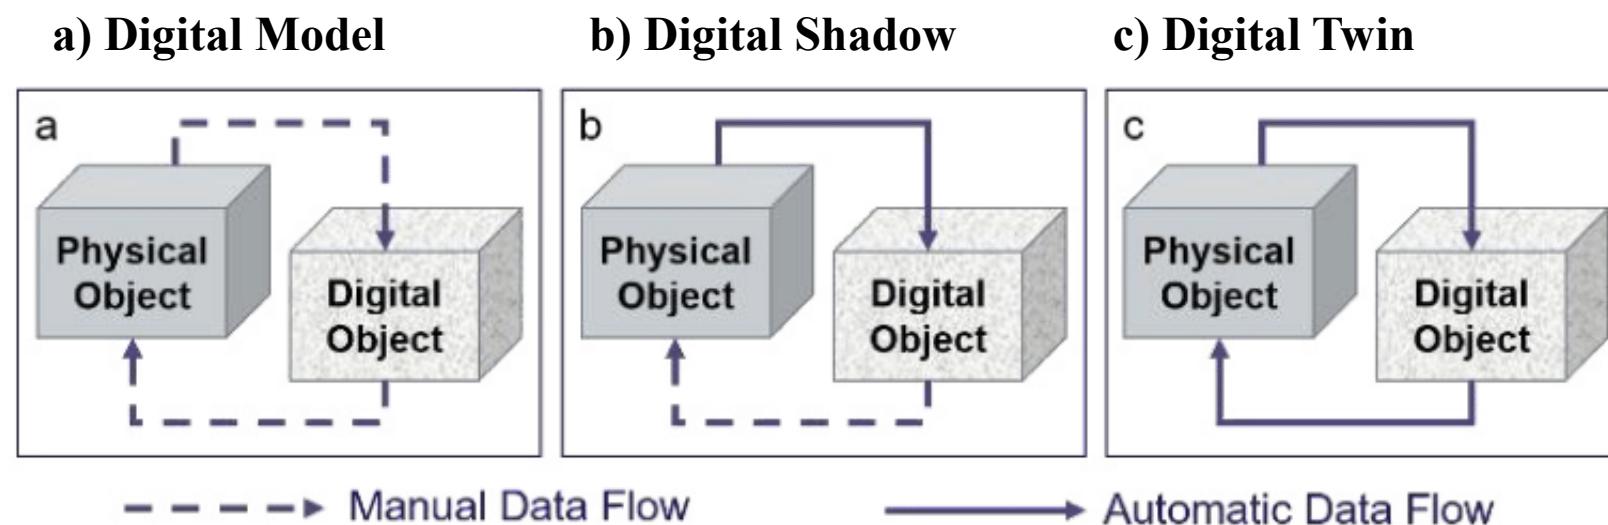
1.4.2 Objetivos Específicos

1. Modelar e validar experimentalmente o módulo fotovoltaico do estudo;
2. Coletar dados ambientais reais de irradiação e temperatura, por meio de sensores instalados no mesmo plano do módulo fotovoltaico físico;
3. **Dimensionar** e modelar o sistema fotovoltaico completo, composto por módulo FV, controlador de carga, bateria e carga no ambiente MATLAB/Simulink e **gerar dados sintéticos rotulados** (operação normal 0 e com sombreamento parcial 1);
4. Treinar e validar um modelo de aprendizado de máquina ***Random Forest***, capaz de classificar estados de operação normal e anormal do sistema fotovoltaico;
5. Integrar o sistema físico, o modelo digital do sistema e o modelo de aprendizado de máquina, por meio de sensores e uma plataforma IoT em nuvem, de modo a garantir a interação dinâmica entre eles, constituindo o GDH.
6. Testar e validar o GDH através de teste em bancada e em campo.



2.1 Gêmeos digitais Conceito e arquitetura (1)

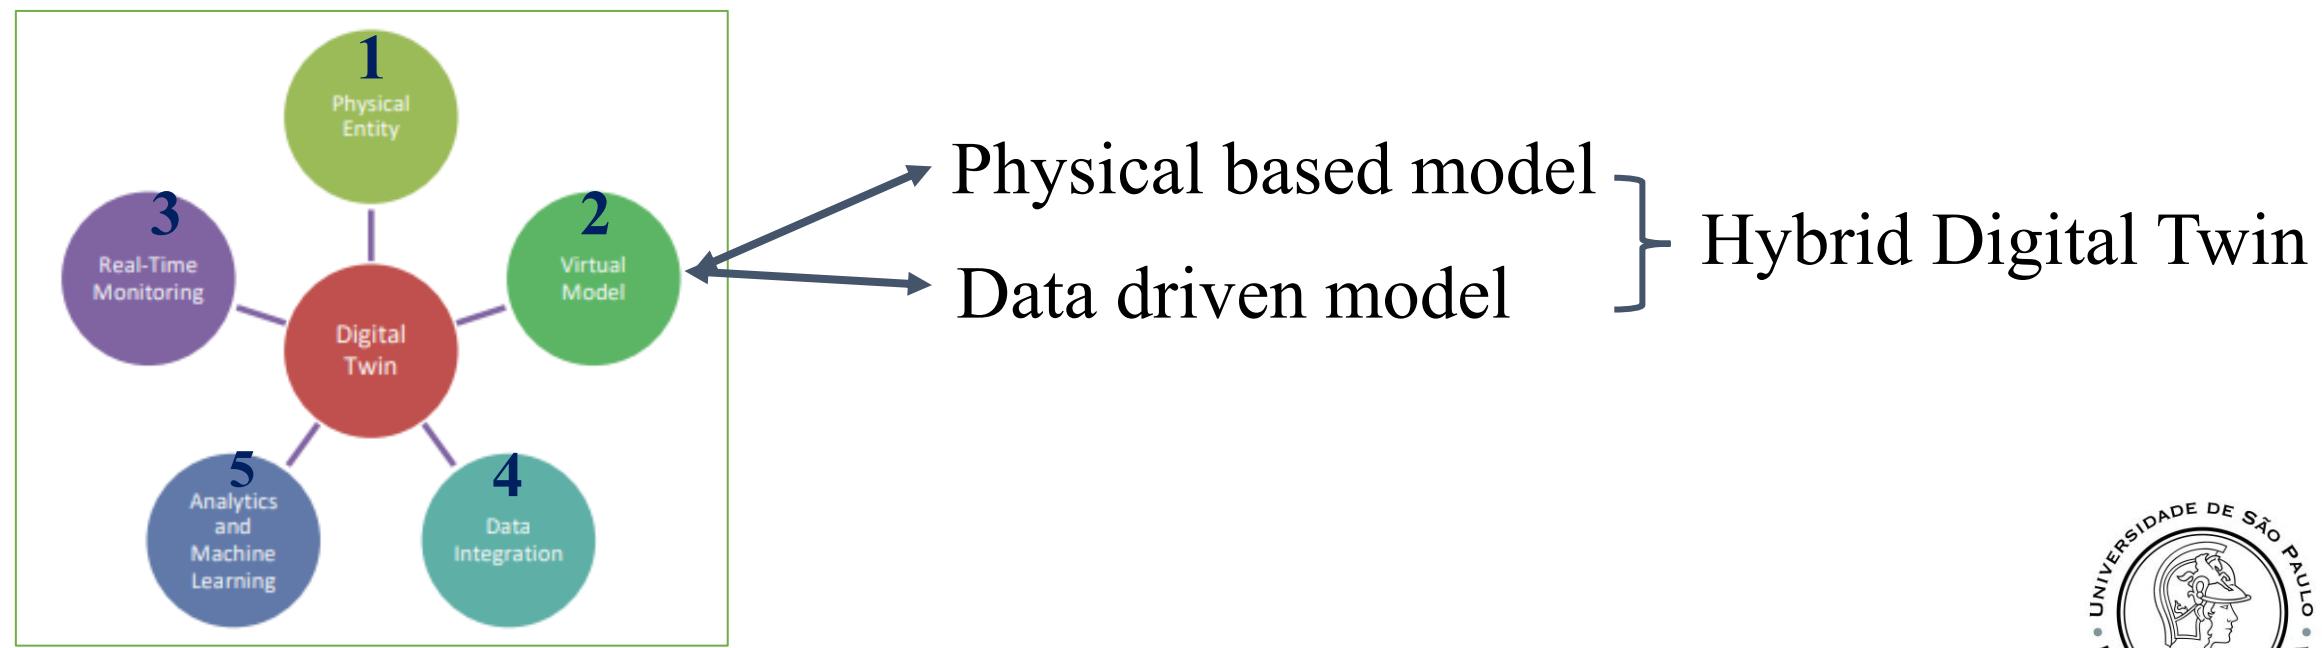
Um gêmeo digital (DT) é uma representação virtual dinâmica de um ativo físico, continuamente sincronizada com seu correspondente real por meio de fluxos bidirecionais de dados, permitindo simular o comportamento, monitorar o estado, detetar e diagnosticar falhas, e otimizar o desempenho do sistema em tempo real. (Grieves et al., 2016; Tao et al., 2018). Um DT não deve ser confundido com:



Um DT é um "espelho dinâmico" do ativo físico, não uma simulação estática!

2.1 Gêmeos digitais (DT) Conceito e arquitetura (2)

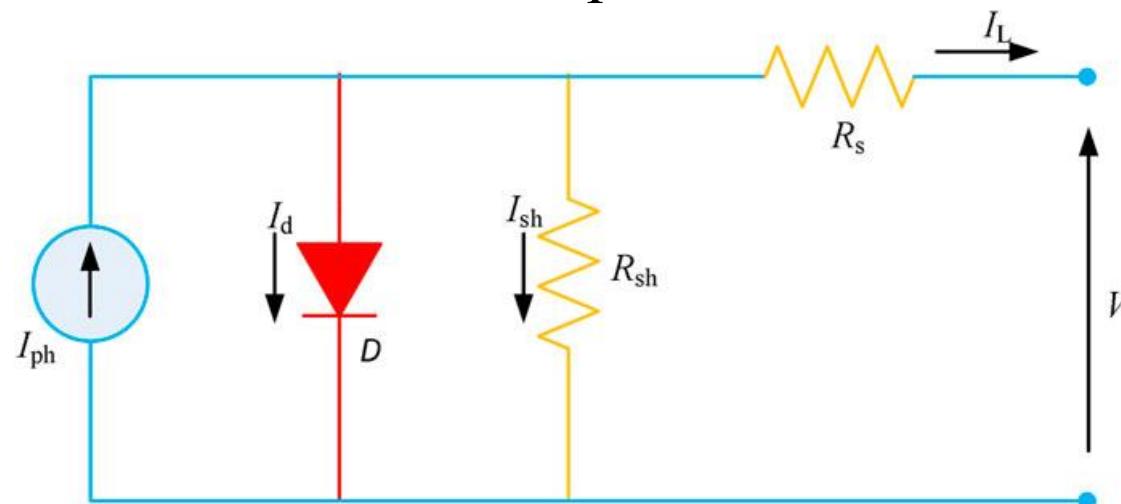
Um DT típico é estruturado em **cinco camadas interligadas**, que inclui: (i) **entidade física**; (ii) **modelo digital de alta fidelidade**; (iii) **integração de dados** em tempo real; (iv) **mecanismos de vinculação** (conexão contínua entre físico e virtual); e (v) **serviços** de valor como diagnóstico, previsão e otimização, implementados por meio de análise de dados e aprendizado de máquina



Um DT é um "espelho dinâmico" do ativo físico, não uma simulação estática!

2.2 O Modelo de Díodo Único (SDM)

O **Modelo de Díodo Único** (Single Diode Model - SDM) é um **circuito elétrico equivalente** que representa o comportamento da célula ou do módulo fotovoltaico como uma fonte de corrente (I_{ph}) em paralelo com uma resistência de derivação (R_{sh}) e um díodo ideal, e em série com uma resistência (R_s). I_{ph} representa a corrente fotogerada enquanto o díodo ideal, simula a junção P-N sob diferentes condições de operação. O SDM tem 5 (I_{ph} , I_0 , R_s , R_{sh} e n) parâmetros que precisam ser estimados com precisão.



Fonte: (Wang et al., 2021)

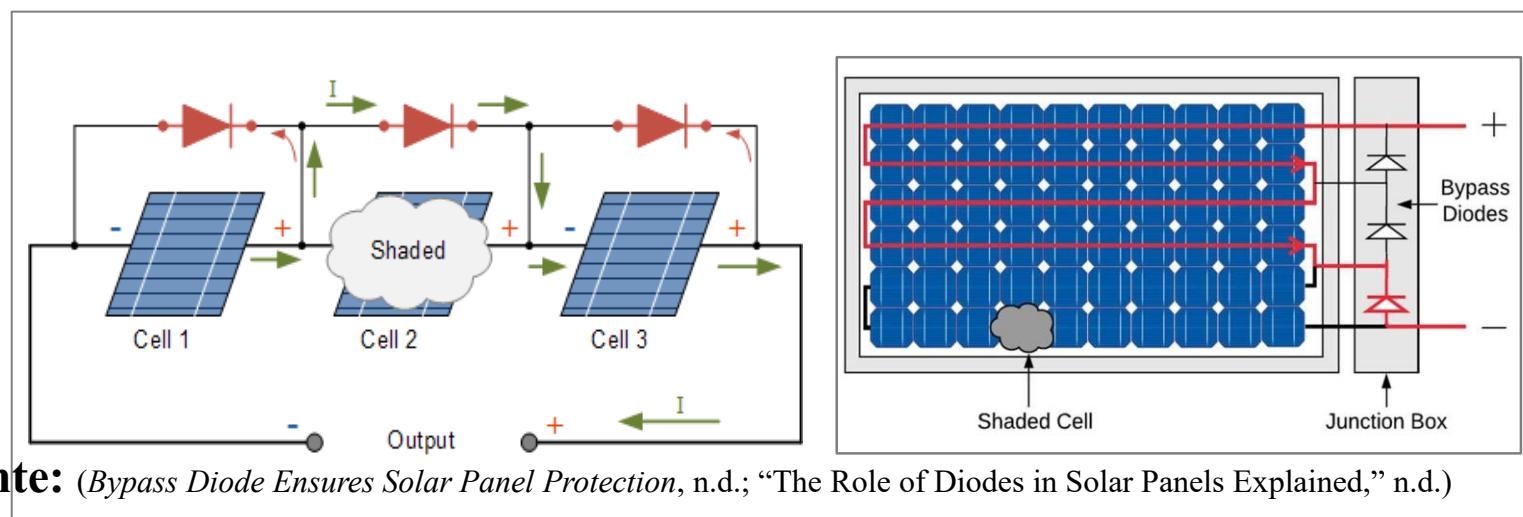


O SDM é um modelo físico robusto e com complexidade adequada para ser o coração de um DT embarcado.

2.3 Técnica de detecção de falhas por sombreamento parcial em SFVs (1)

Díodo de Bypass

A primeira linha de defesa contra os efeitos mais severos do sombreamento parcial, que não é listado dentre os métodos propriamente dito, é implementada a nível de hardware por meio de díodos de *bypass*. Conectados em anti-paralelo com subconjuntos de células (tipicamente 18 a 24) dentro de um módulo fotovoltaico. Sua função é desviar a corrente gerada pelas células iluminadas quando uma ou mais células do grupo operam em polarização reversa devido ao sombreamento, evitando a dissipação excessiva de potência como calor e, consequentemente, a formação de pontos quentes (*hot spots*) que podem causar danos físicos irreversíveis, como carbonização do encapsulante ou trincas térmicas nas células.



Resultado: Salva as células de hot spot e de queima, no entanto a parte retirada eletricamente do circuito deixa de produzir energia temporariamente, e confundem os CCMPPPT convencionais, mas isso é preferível à destruição permanente do módulo.

Fonte: (Bypass Diode Ensures Solar Panel Protection, n.d.; “The Role of Diodes in Solar Panels Explained,” n.d.)



A durante as medições se interrompe a operação do sistema fotovoltaico e suspende a geração de energia.

2. Fundamentação Teórica

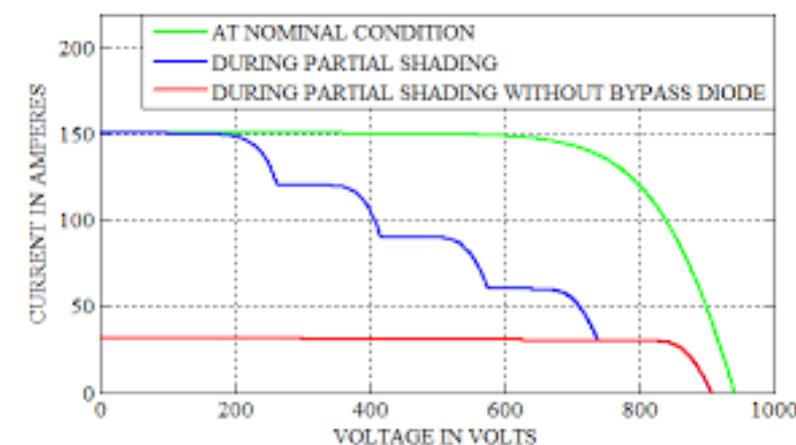
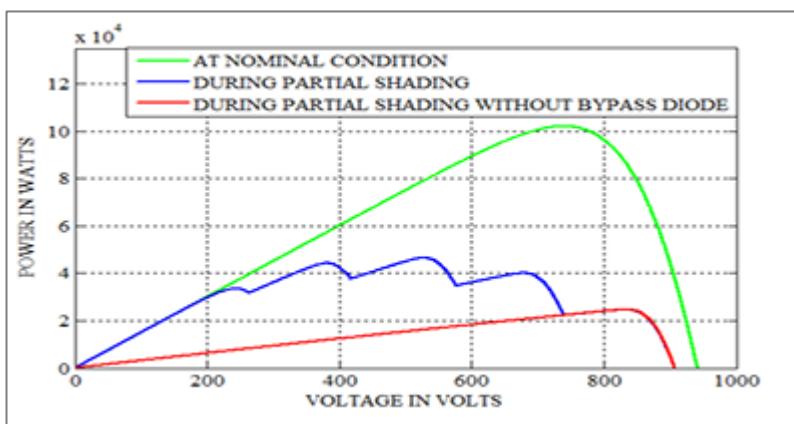
2.3 Técnica de detecção de falhas por sombreamento parcial em SFVs (2)

Métodos baseados em medições elétricas

Envolvem a análise das características elétricas dos sistemas fotovoltaicos. Faz-se medição de parâmetros críticos, como a tensão, a corrente e a potência de saída, diretamente dos painéis fotovoltaicos (Pei & Hao, 2019). O método mais comum é a análise da curva I–V e P–V, onde a presença de múltiplos picos locais indica a ativação de diódos de bypass e o desbalanceamento entre submódulos (Cáceres et al., 2020; Campos et al., 2025; Li et al., 2021, 2023).



Fonte: (*Understanding the IV Curve Tracer for Commissioning PV Systems*, n.d.)



(Fonte: Choudhury et al., 2015)

A durante as medições se interrompe a operação do sistema fotovoltaico e suspende a geração de energia.

Resultados bons, mas
requerem condições
controladas de irradiação e
são realizados com o
sistema desligado

2.3 Técnica de detecção de falhas por sombreamento parcial em SFVs (3)

Métodos baseados em imagens - termografia

Não invasivos, fornecerem **feedback imediato** e permitirem avaliar a integridade física e operacional dos módulos FV sem **interromper a produção de energia**. É **amplamente utilizada em campo** para detectar variações de temperatura superficial entre células, permitindo a identificação de **hot spots**, **ativação de díodos de bypass**, padrões térmicos assimétricos e regiões submetidas a estresse térmico causado por PSC (de Souza Junior et al., 2024).



Fonte: (Thermal Imaging for Solar Panel Inspection | Atlantic Testing Services, n.d.)



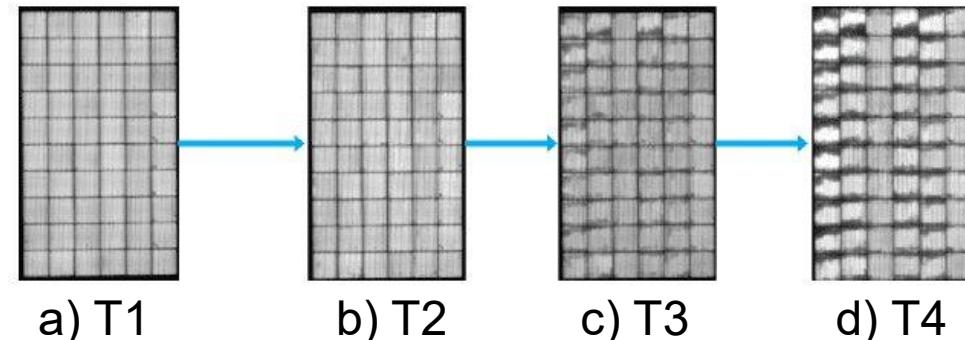
O problema não é a temperatura, mas sim o gradiente de temperatura entre pontos diferentes.

2. Fundamentação Teórica

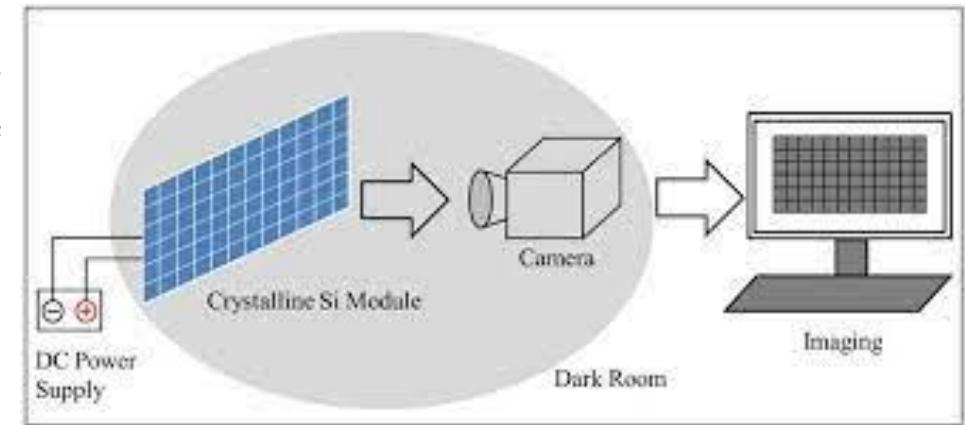
2.3 Técnica de detecção de falhas por sombreamento parcial em SFVs (4)

Métodos baseados em imagens – eletroluminescência

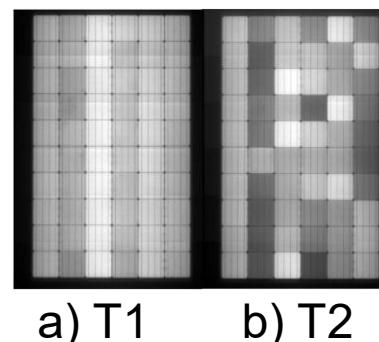
Polarizar eletricamente o módulo, fazendo com que as células emitam radiação no espectro do infravermelho próximo (NIR) que não é visível ao olho humano. Câmeras especiais ou modificadas, com filtros infravermelhos removidos, capturaram essa emissão, produzindo imagens que revelam microfissuras, células quebradas, defeitos de contato, regiões degradadas e hot spots latentes, permitindo uma avaliação aprofundada da integridade e da qualidade do módulo..



Fonte: (*O Que é a Lista Tier 1 e Qual Sua Relação Com a Qualidade Do Módulo?*, n.d.)



Fonte: (Xiao et al., 2016)



Fonte: (Koester et al., 2022)



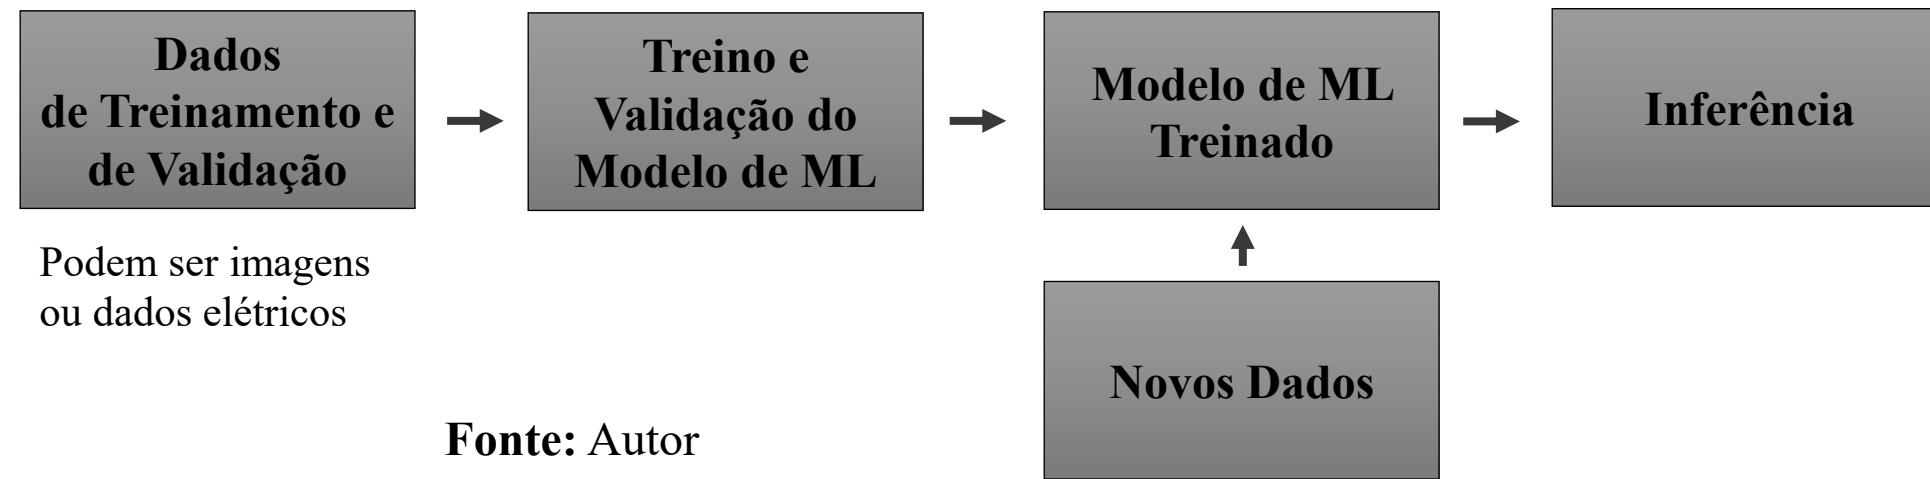
Alta precisão, revela danos muitas vezes já irreversíveis — e exige infraestrutura especializada.

2. Fundamentação Teórica

2.3 Técnica de detecção de falhas por sombreamento parcial em SFVs (5)

Métodos baseados em Inteligência Artificial IA

1. Usam dados resultantes das primeiras duas aboradagens: imagens (termografia, EL, RGB) ou dados elétricos e ambientais (I, V, P, G, T).
2. Treinam modelos de machine learning (ML): algoritmos aprendem padrões estatísticos nos dados.
3. O modelo de ML faz inferência: detecção/diagnóstico de falhas quando lhe fornecem novos dados.



O desempenho do modelo de ML está diretamente ligada a quantidade e qualidade dos dados com que é treinado.

3. Trabalhos Relacionados

3.1 Trabalhos que usam IA para detecção de PSC em SFVs

Trabalho	Contribuições	Limitações
(Akram et al., 2020)	<p>DL para deteção automática de defeitos em imagens de termografia</p> <p>Alta acurácia (98–99%)</p> <p>Inferência rápida por imagem (13 ms)</p> <p>Identificação de hotspots, shunts e defeitos estruturais.</p>	<p>Não opera em tempo real contínuo</p> <p>Não usa dados elétricos nem ambientais</p> <p>Não é embarcado</p> <p>O custo não compensa o benefício, para pequenos sistemas PV...</p>
(Bu et al., 2023)	<p>DL para detecção automática de defeitos em imagens de termografia</p> <p>Alta acurácia (97,4%)</p> <p>Inferência rápida por imagem (0,134 ms)</p> <p>Dataset expandido via data augmentation</p> <p>Identificação hot spot, cracking, no-fault.</p>	<p>Não opera em tempo real contínuo</p> <p>Não usa dados elétricos nem ambientais</p> <p>Não é embarcado</p> <p>Sem aprendizado contínuo</p> <p>Inviável para pequenos sistemas PV</p>

Alta acurácia porém, off-line e inviável para pequenos sistemas.



3. Trabalhos Relacionados

3.2 Trabalhos que usam DT para detecção de PSC em SFVs

Trabalho	Contribuições	Limitações
(P. Jain et al., 2020)	<ul style="list-style-type: none">➤ Conversor DC/DC próprio, com hardware e firmware integrados para diagnóstico baseado em modelo físico➤ Detecta até 10 tipos de falhas (painel, conversor e sensores).➤ Diagnóstico rápido (0,29 ms – 1200 ms).➤ Conversor funciona como plataforma única de medição + processamento.➤ Validado em protótipo de 300 W em campo real.	<ul style="list-style-type: none">➤ Requer hardware específico — conversor customizado; não aplicável a inversores comerciais.➤ Complexo de replicar devido ao hardware não comercial.➤ Não é um DT completo — fluxo físico → digital (Digital Shadow).
(Idrissi Kaitouni et al., 2024)	<ul style="list-style-type: none">➤ Implementa um DS urbano para monitorar cinco sistemas fotovoltaicos distribuídos.➤ Utiliza um modelo físico global de previsão de potência (PVWatts).➤ Consolida dados operacionais usando SCADA e controladores lógicos programáveis (CLPs).➤ Contribui com um framework de manutenção preventiva e planejamento energético em ambientes urbanos.	<ul style="list-style-type: none">➤ O PVWatts é um modelo global, não permite diagnóstico em nível de módulo, nem análise detalhada das grandezas elétricas (V, I, G, T).➤ Infraestrutura centralizada (SCADA + CLP), não embarcado.➤ Não existe sincronização bidirecional contínua entre o sistema físico e o modelo digital (Digital Shadow).
(Kolahi et al., 2024)	-----	-----

Não realizam diagnóstico elétrico em tempo real com sincronização contínua físico-digital



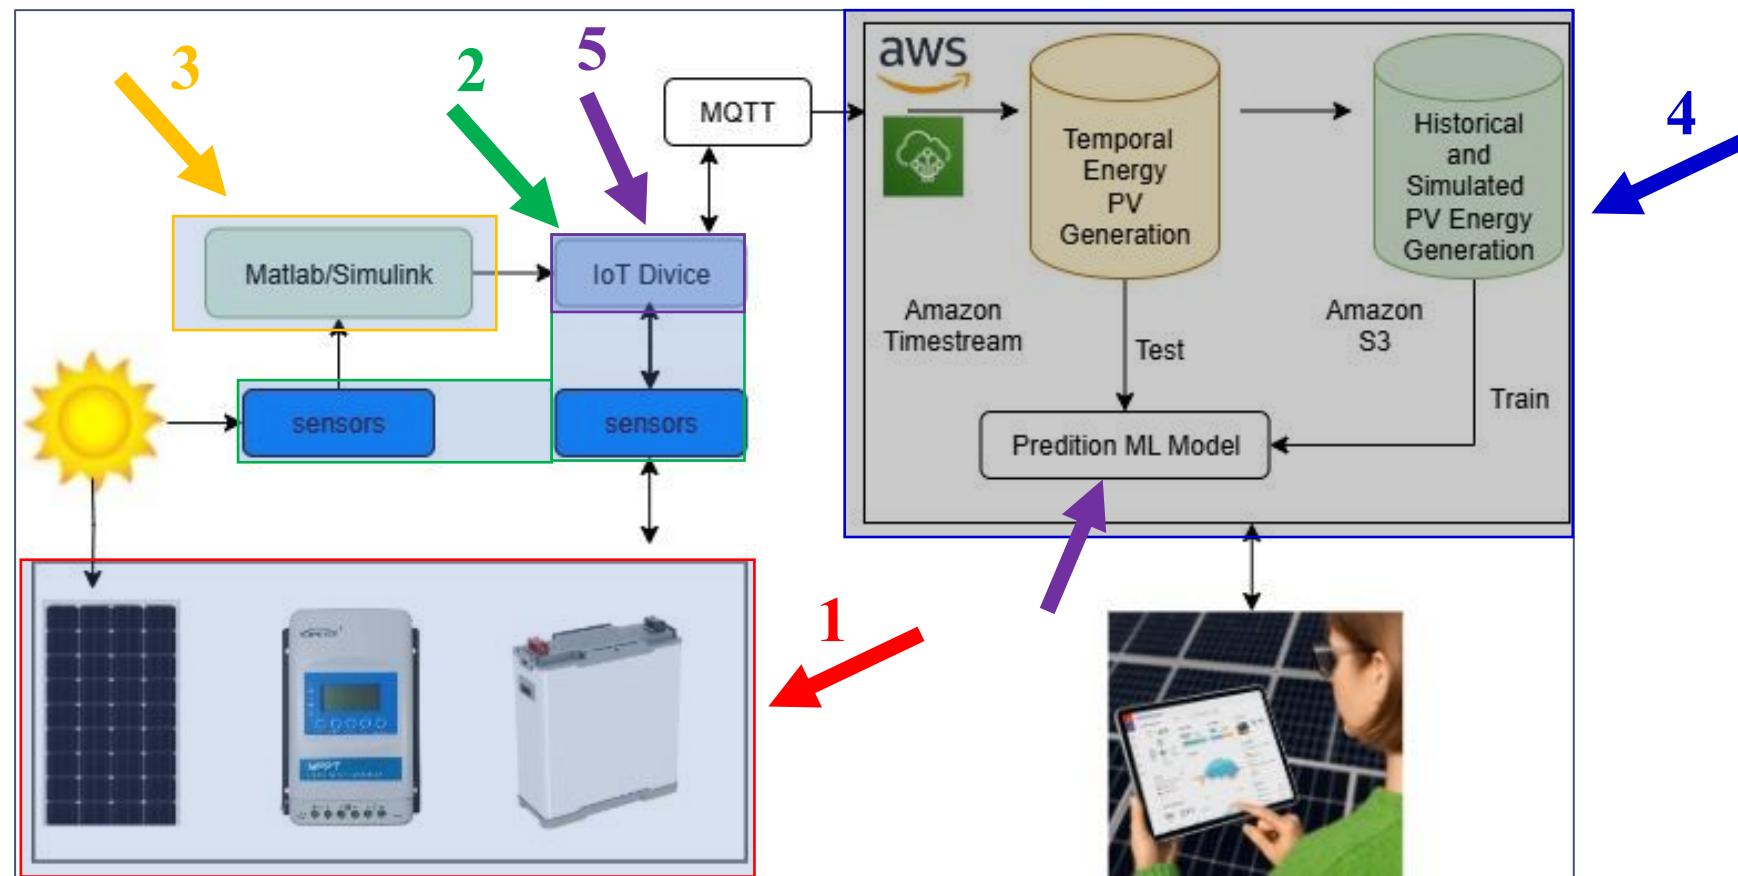
3. Trabalhos Relacionados

3.2 Trabalhos que usam DT para detecção de PSC em SFVs

Trabalho	Contribuições	Limitações
(P. Jain et al., 2020)	-----	-----
(Idrissi Kaitouni et al., 2024)	-----	-----
(Kolahli et al., 2024)	<ul style="list-style-type: none">➤ Desenvolve uma plataforma virtual completa para simulação de plantas fotovoltaicas de grande porte, usando Unreal Engine e AirSim.➤ Permite simular voos autônomos de drones, planejamento de rotas e captura simulada de imagens.➤ Gera um dataset sintético realista (2.469 imagens) com anotações de defeitos visuais (ex.: sujidade por fezes de pássaros).➤ Treina e valida um modelo de segmentação baseado em visão computacional (FCN + VGG16) com acurácia de 95%.➤ Fornece ambiente seguro e de baixo risco para testar algoritmos de navegação, detecção de anomalias e inspeção aérea antes da implementação no campo real.➤ Simula diferentes condições ambientais, iluminação e cenários operacionais.	<ul style="list-style-type: none">➤ Não monitora dados elétricos (V, I, P, G, T).➤ Não opera em tempo real — não recebe dados contínuos de operação.➤ Baseado em dados de imagens (drones, câmeras).➤ Sem integração IoT e sem pipeline embarcado.➤ É apenas um Digital Model — totalmente desconectado do sistema físico (sem dados reais e sem sincronização).➤ Inviável para pequenos sistemas.

4.1 Gêmeo Digital Hibrido (GDH base - A0) (1)

Na perspectiva de suprir as limitações identificadas no estado da arte, propomos um GDH embarcado, que seja capaz de aprender continuamente e detectar e diagnosticar em tempo real falhas por sombreamnto parcial em SFVs. O GDH proposto é estruturado em cinco camadas fundamentais que operam de forma coordenada:



Fonte: Autor

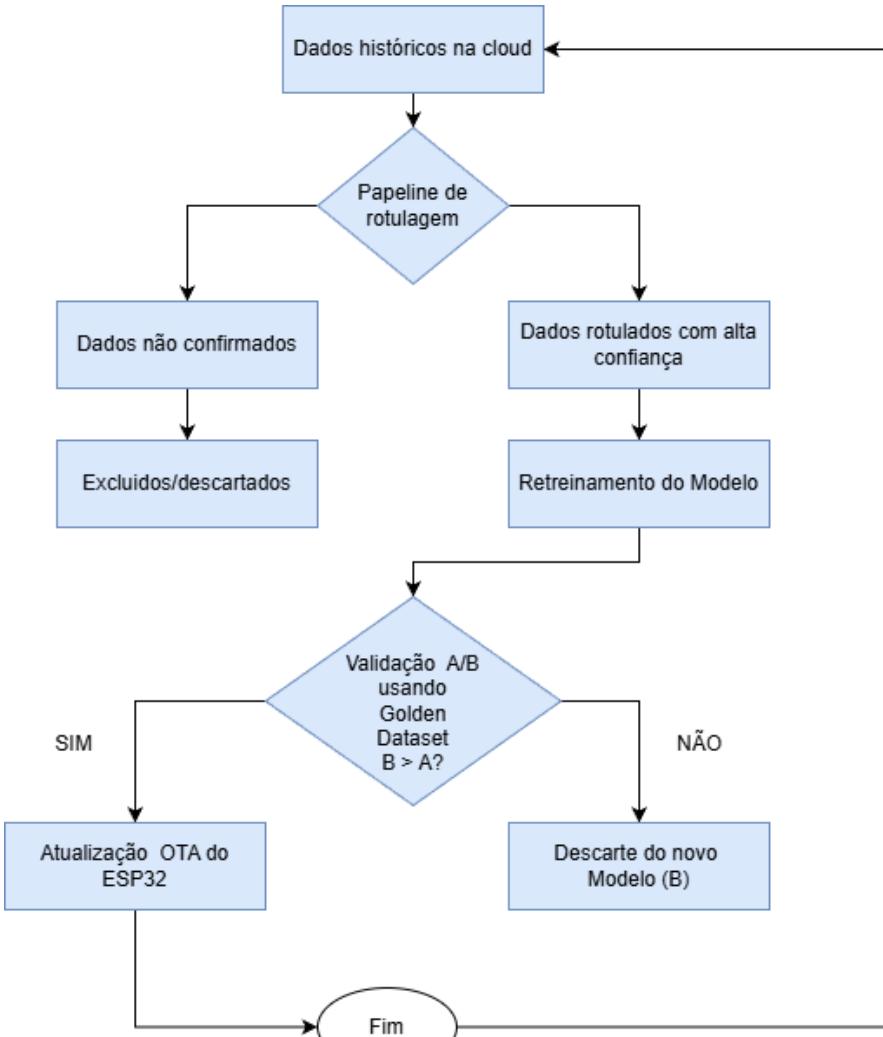
Essas camadas correspondem a um DT propriamente dito!

4.1 Gêmeo Digital Hibrido (GDH base - A0) (2)

- 1. Sistema Físico:** Corresponde ao ativo real – o sistema fotovoltaico de pequeno porte – devidamente instrumentado com sensores para aquisição de tensão, corrente, irradiação solar e temperatura ambiente.
- 2. Camada de Aquisição e Diagnóstico no Edge:** Implementada num microcontrolador ESP32, esta camada é responsável pela aquisição de dados em tempo real, seu pré-processamento e pela execução local do modelo de *Machine Learning* para diagnóstico.
- 3. Modelo Virtual (Gêmeo Digital):** Uma réplica computacional do sistema físico, desenvolvida no ambiente MATLAB/Simulink e fundamentada no Modelo de Díodo Único (SDM), validado experimentalmente. Este modelo gera os valores de referência esperados para o comportamento elétrico do sistema sob as condições ambientais medidas.
- 4. Infraestrutura em Nuvem:** Atua como o sistema nervoso central, utilizando plataforma AWS IoT para comunicação bidirecional, armazenamento de dados históricos (em serviços como Amazon S3) e orquestração entre o *edge* e o modelo virtual.
- 5. Modelo Inteligente de Diagnóstico:** O coração cognitivo do sistema. Um modelo de *Random Forest*, treinado e validado.



4.1 Gêmeo Digital Hibrido (GDH base - A0) (3)

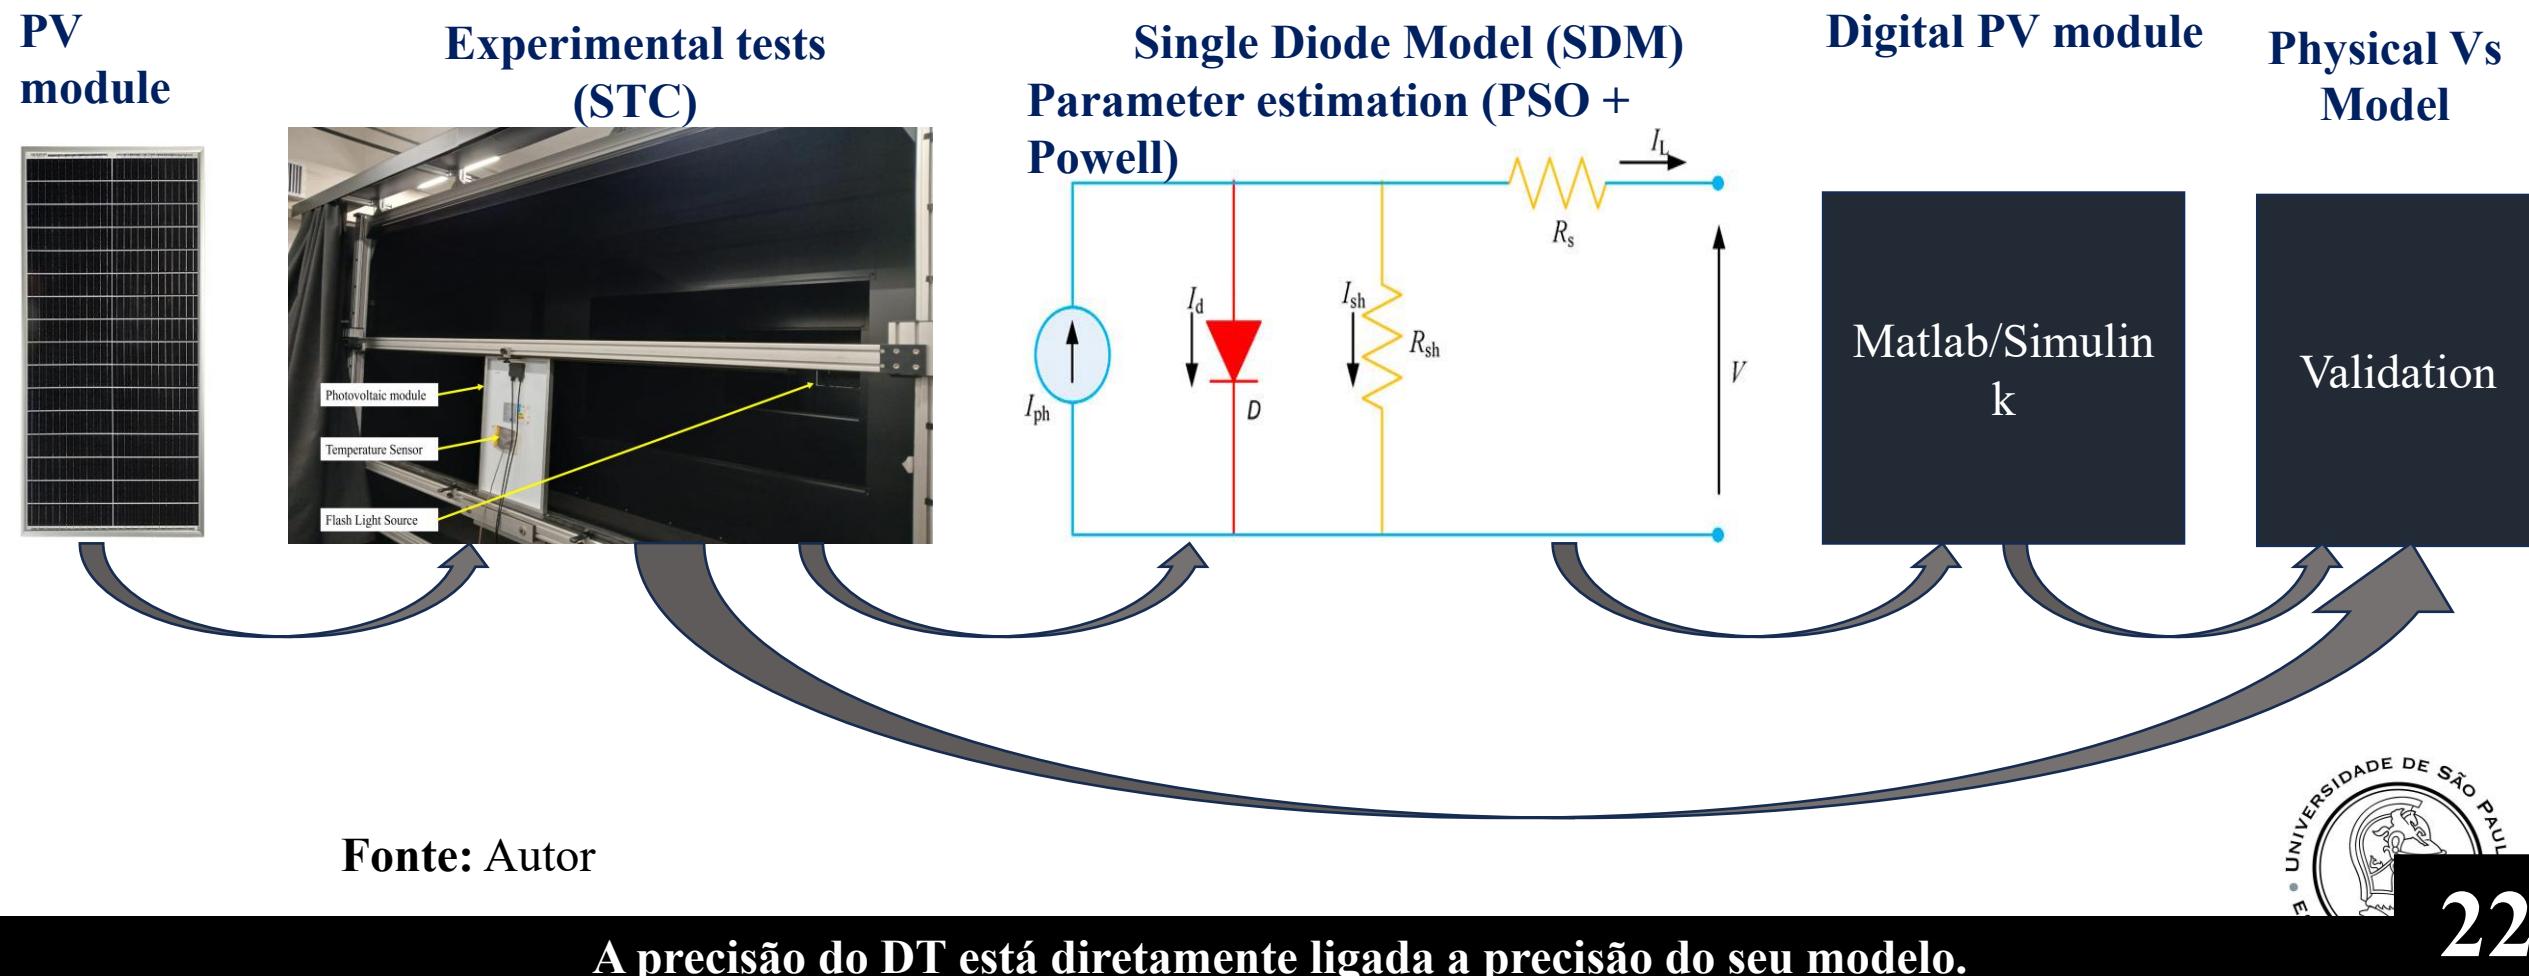


- O GDH é concebido para ser capaz de **aprender continuamente** ao longo de sua vida útil.
- A partir de **dados históricos** na nuvem, criados através de um **pipeline de rotulagem** automática, baseado num **consenso** entre o modelo físico (**SDM**) e o modelo de **ML existente**, que identifica e rotula novos dados de falhas com alta confiança, **o modelo de ML A é retreinado e validado** na base de dados de referência (**Golden dataset**) resultando num **novo modelo B**
- Um mecanismo de comparação **A/B** é acionado. Se **B>A** o modelo A é então a substituído por B se tornando na nova versão de A, caso contrário, A é mantido e esse ciclo se repete.

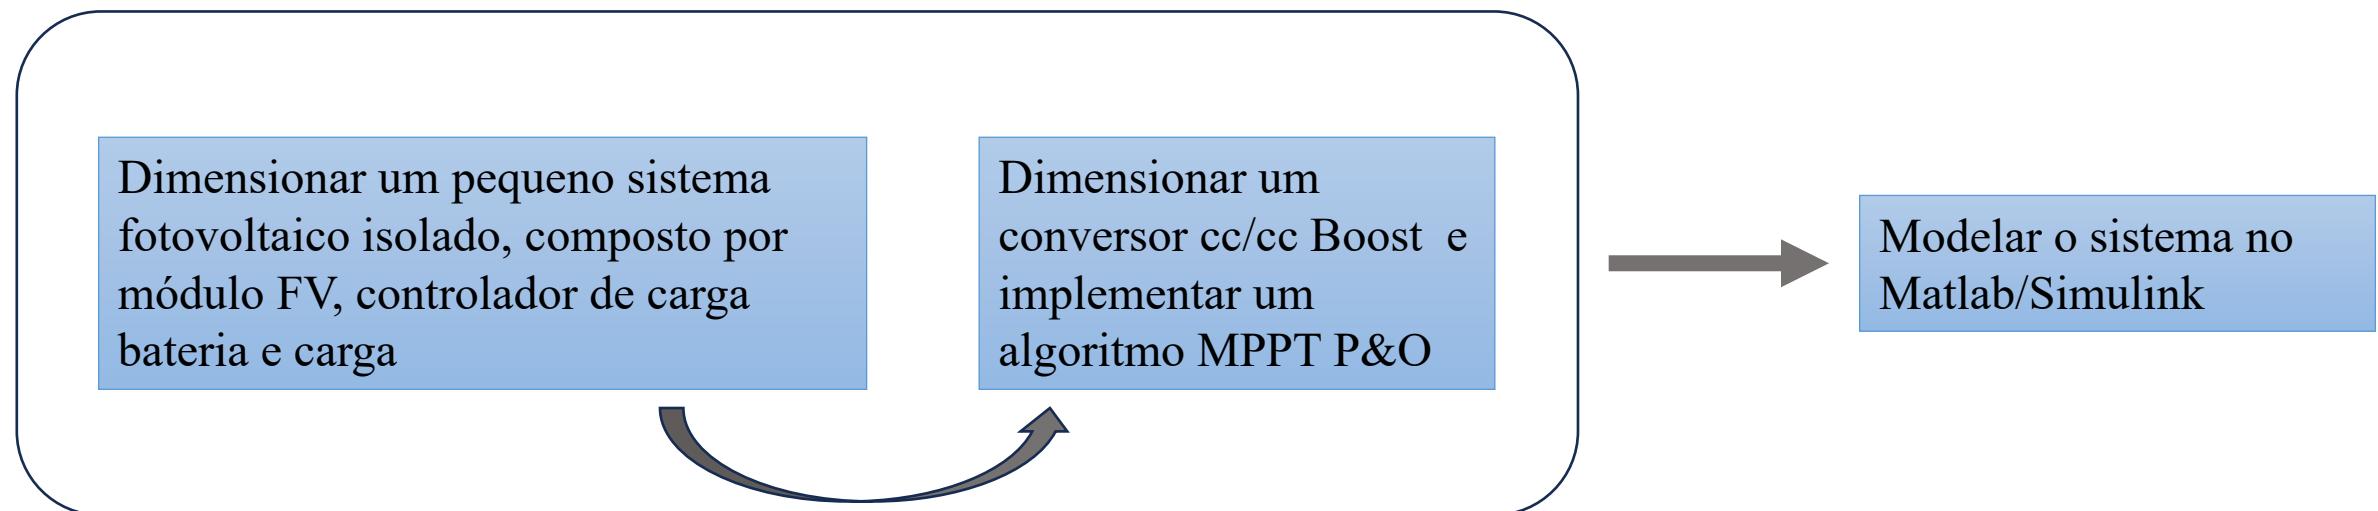
Esta capacidade confere ao GDH autonomia para se adaptar e melhorar continuamente, tornando-o inteligente.

5. Metodologia

5.1 Modelagem e Validação Experimental do Módulo Fotovoltaico



5.2 Desenvolvimento do modelo digital do sistema no MATLAB/Simulink



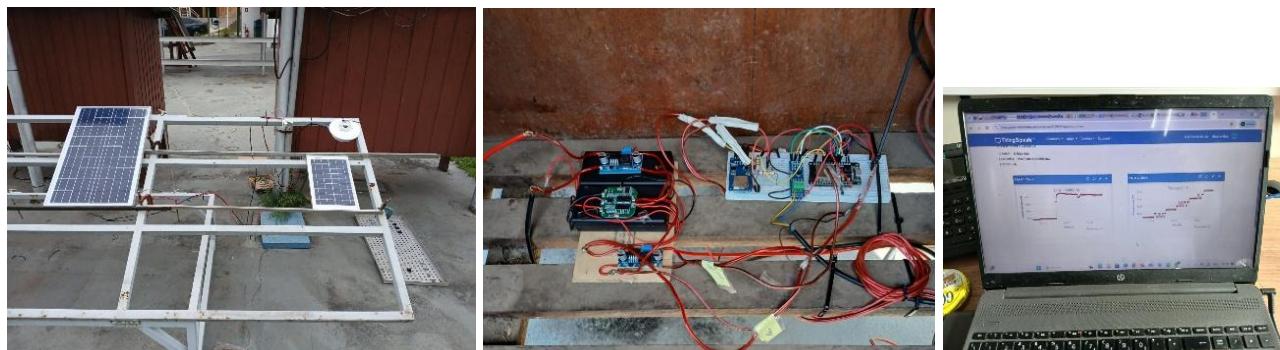
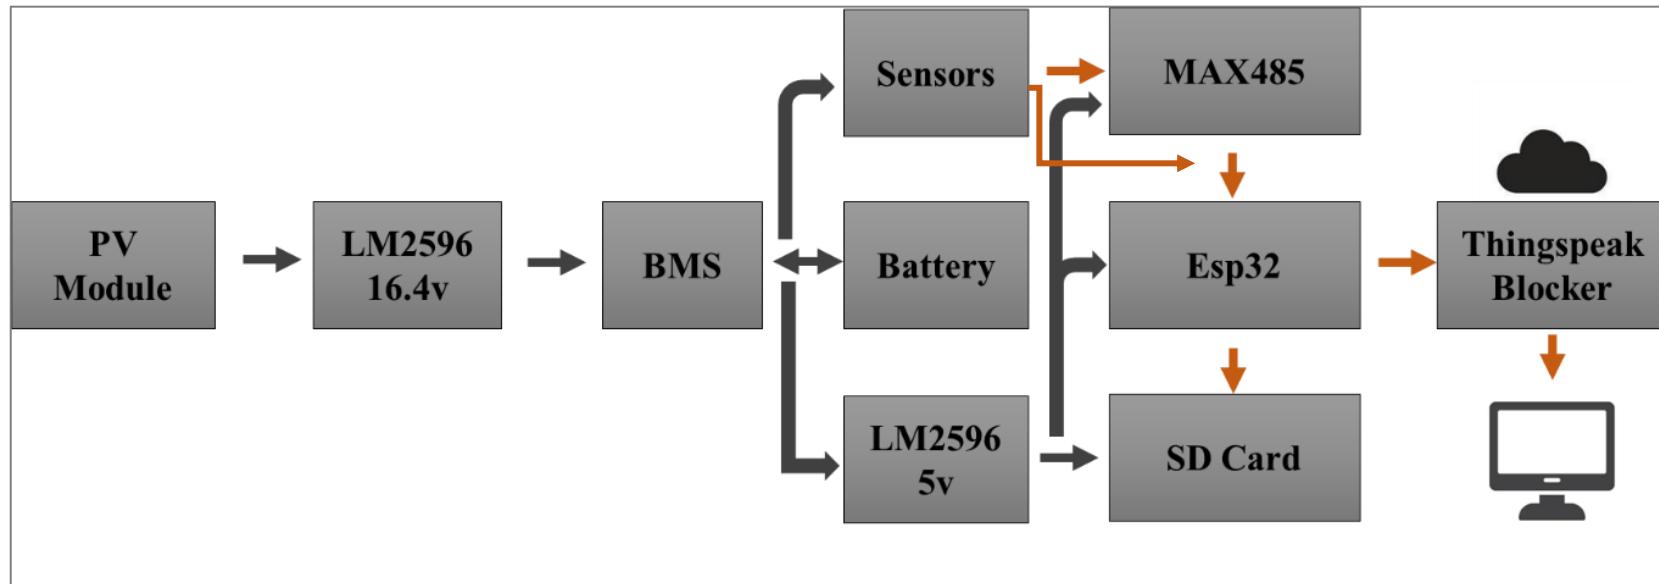
Fonte: Autor

Sistema com autonomia de 2 dias.



5. Metodologia

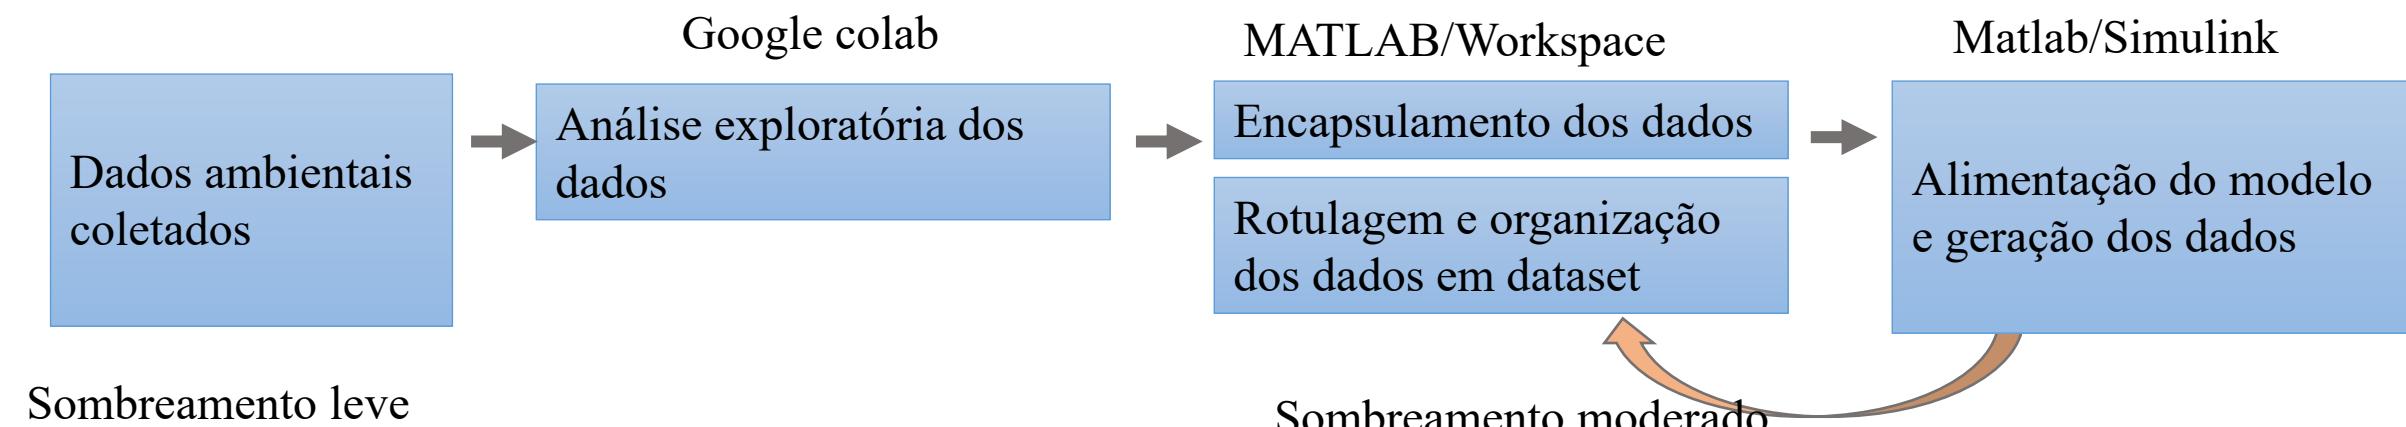
5.3 Aquisição de dados ambientais (irradiância e temperatura)



Fonte: Autor

Dados ambientais de irradiância e temperatura são cruciais na geração de dados sintéticos.

5.4 Geração e gestão de dados para treino de modelo de ML



Sombreamento leve

100%	100%	80%	100%	80%	80%	80%
100%	100%	100%	100%	100%	100%	100%

0%

25%

50%

75%

Estrutura do dataset: (V, I, P, G, T, t)

Sombreamento moderado

70%	100%	70%	70%	70%	70%
100%	100%	100%	100%	100%	100%

25%

50%

75%

$$\begin{aligned} P_{out} &= P_{out_s}/4 \\ V_{out} &= V_{out_s}/4 \\ I_{out} &= I_{out_s} \end{aligned}$$



Sem dados consistentes e bem rotulados, não há diagnóstico preciso de PSC.

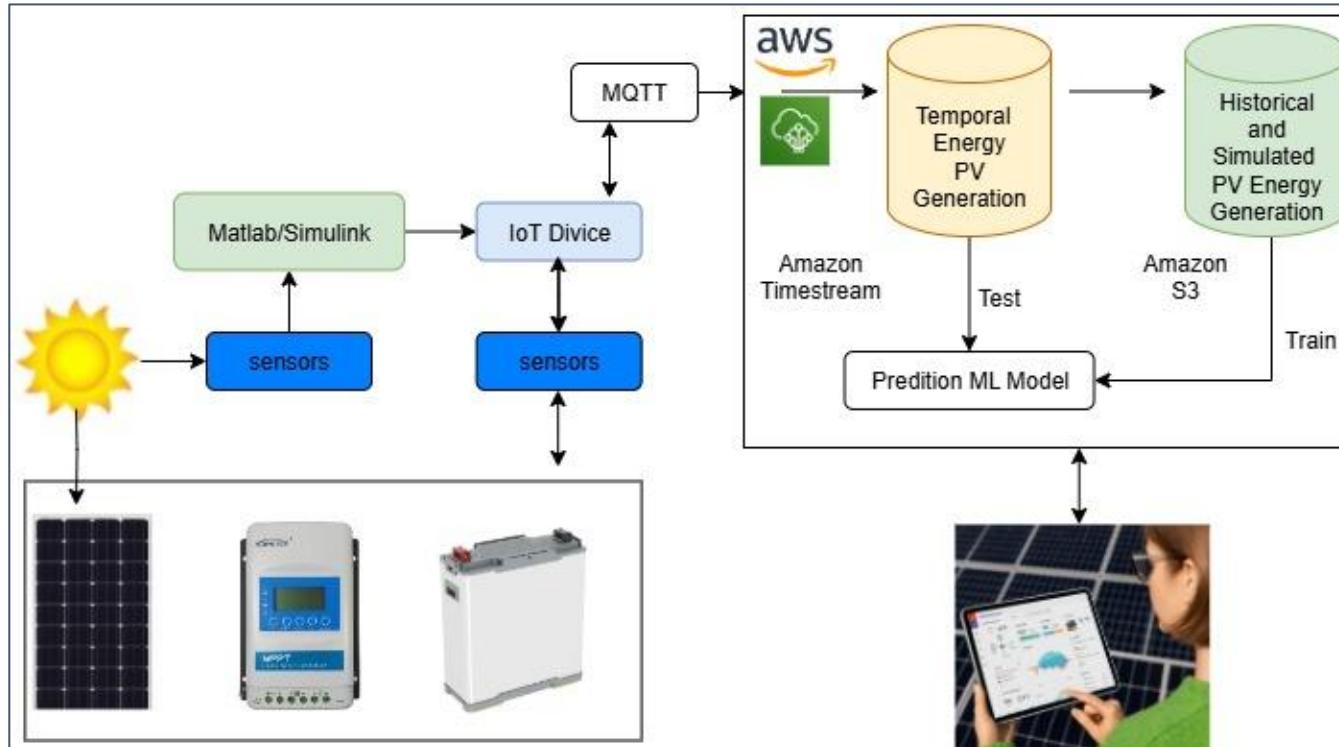
5.5 Treinamento e validação do modelo de ML RF

A ser realizada no Google Colab, seguindo as seguintes etapas:

1. **Análise Exploratória dos Dados (EDA):** verificação de dados inconsistentes, distribuição das features (V, I, P, G, T, t) e correlação; análise do balanceamento das classes.
2. **Pré-processamento:** normalização e divisão estratificada em **70% treino / 15% validação / 15% teste**.
3. **Treinamento:** modelo **Random Forest** a ser treinado com **validação cruzada k-fold (k=5)**.
4. **Avaliação:** acurácia, precisão, recall, F1-Score e matriz de confusão, com visualizações em **Matplotlib/Seaborn**.
5. **Validação Experimental:** teste do modelo em condições reais (0%, 25%, 50%, 75% de PSC) usando dados medidos **do sistema físico**.

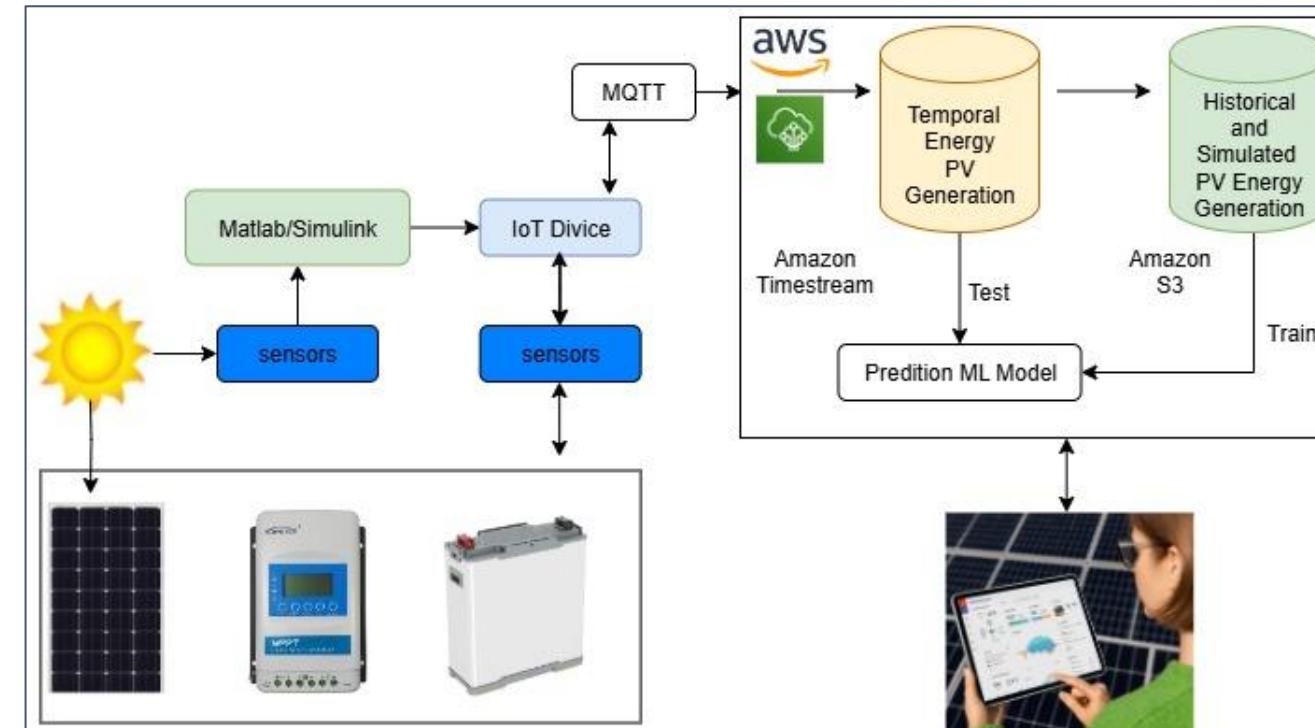


5.6 Integração das partes e implementar o GDH (1)



- **Conversão do SDM para código embarcado (C/C++) usando Simulink Coder**
Modelo do SFV no Simulink será convertido para rodar diretamente no ESP32, para calcular em tempo real a potência de referência P_{ref} .
- **Aquisição de dados do sistema físico (ESP32)**
Sensores de tensão, corrente, irradiação e temperatura serão conectados ao ESP32 para coleta contínua de dados V, I, G, T.
Sincronização e pré-processamento no próprio microcontrolador.

5.6 Integração das partes e implementar o GDH (2)



- Embarcar RF no ESP32 para inferência local
- Conexão com a nuvem via MQQT: armazenamento de dados históricos na nuvem para suporte ao ciclo de aprendizagem contínua.

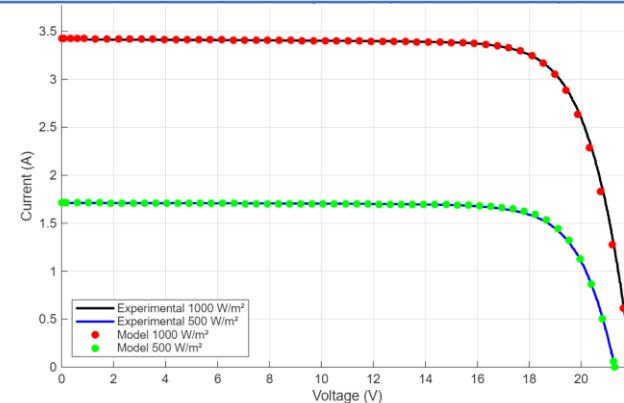
Fonte: Autor

O A0 toma forma.

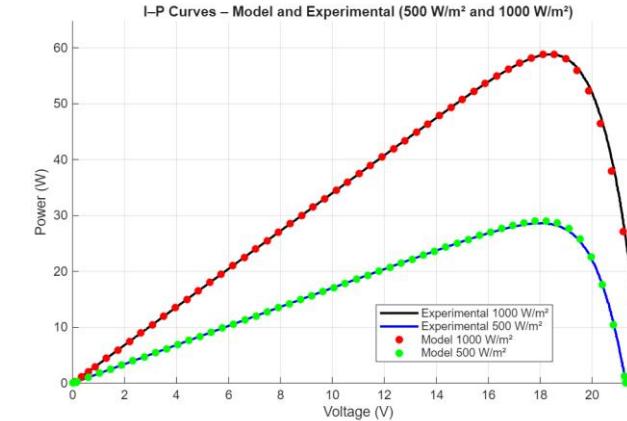
6. Resultados Parciais e Esperados

6.1 Modelagem e validação experimental do módulo

Curva I-V Modelo vs Experimental (500 and 1000 W/m²)



Curva P-V Modelo vs Experimental (500 and 1000 W/m²)

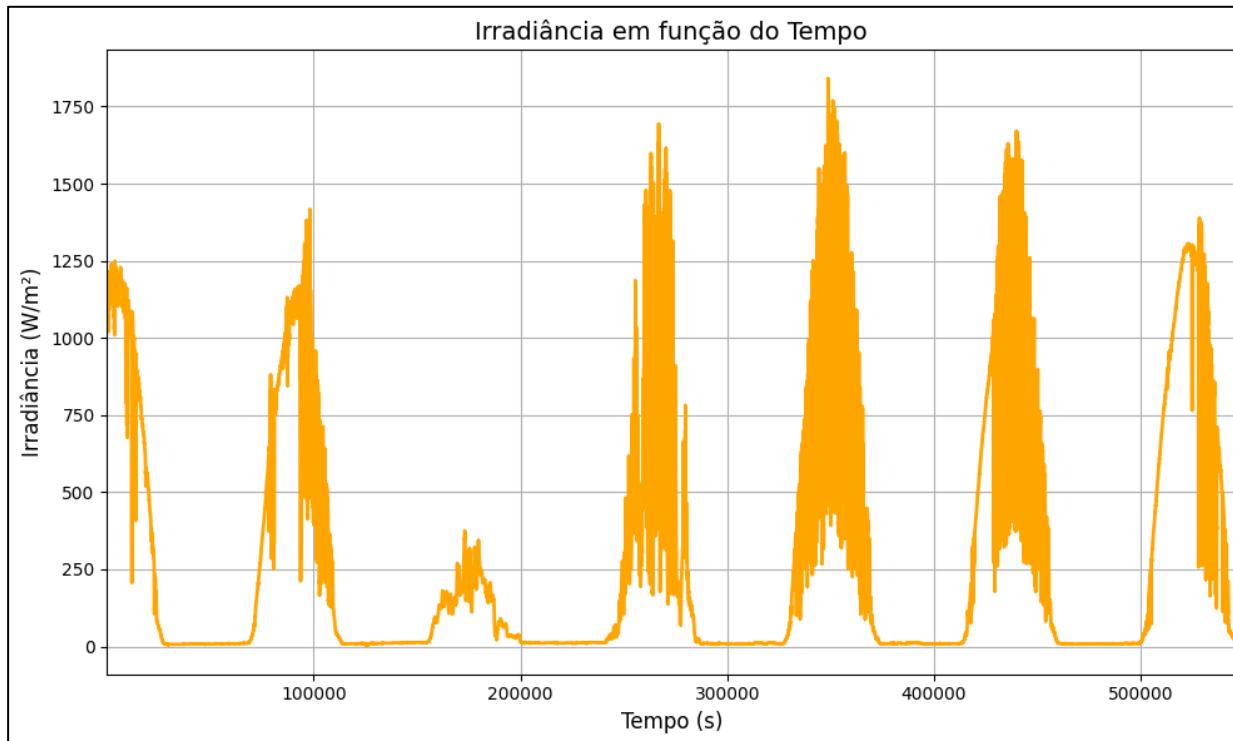


Metrics	I-V		I-P	
	1000 W/m ²	500 W/m ²	1000 W/m ²	500 W/m ²
MAE (A W)	0.0156	0.0061	0.2932	0.1021
RMSE (A W)	0.0333	0.0094	0.7025	0.1809
R ²	0.9983	0.9993	0.9985	0.9996
MAPE (%)	1.36	0.90	1.39	0.93

Metrics	Good Range	References
MAE	< 0.05 A e < 0.5 W	Silva et al., 2020
RMSE	< 0.1 A e < 1 W	Villalva et al., 2019
R ²	0.995–0.999 V.E	Silva et al., 2020
MAPE (%)	1–3% V.E	Khan et al., 2019

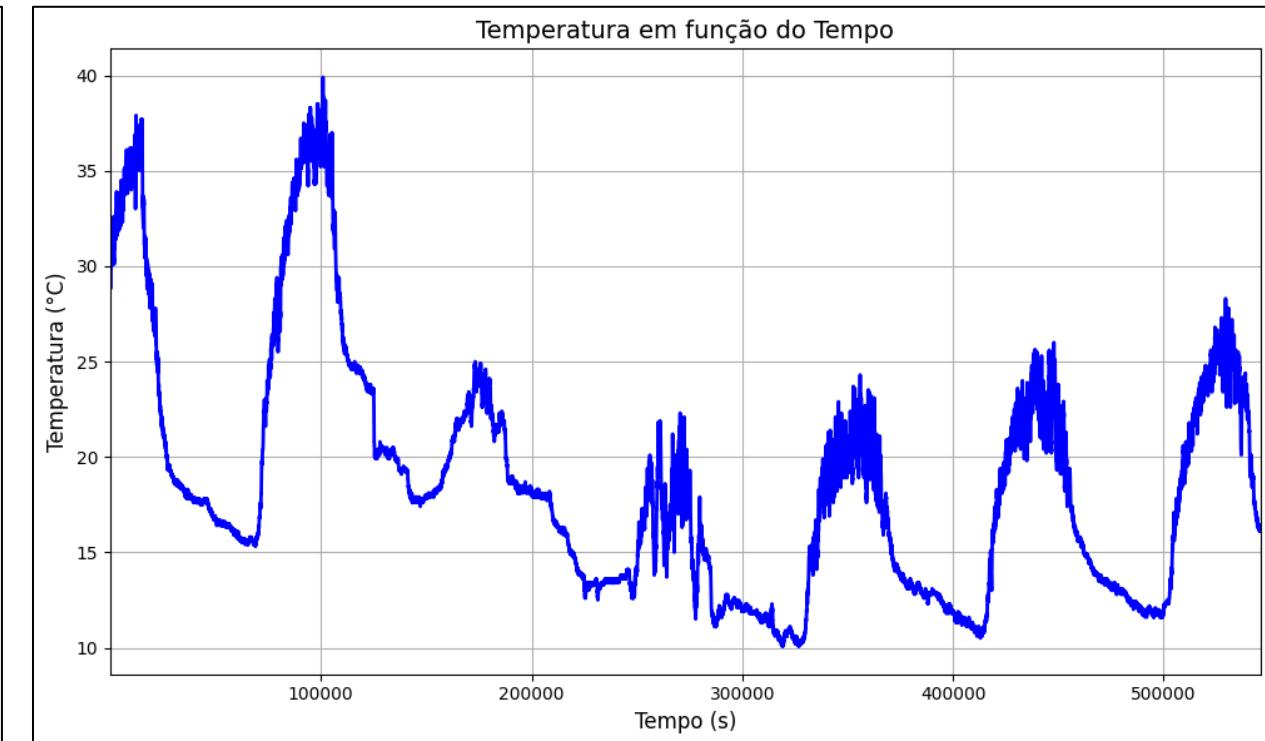
6. Resultados Parciais e Esperados

6.2 Aquisição de dados ambientais em condições reais



a) Solar irradiance;

Fonte: Autor



b) Temperatura ambiente em função do tempo

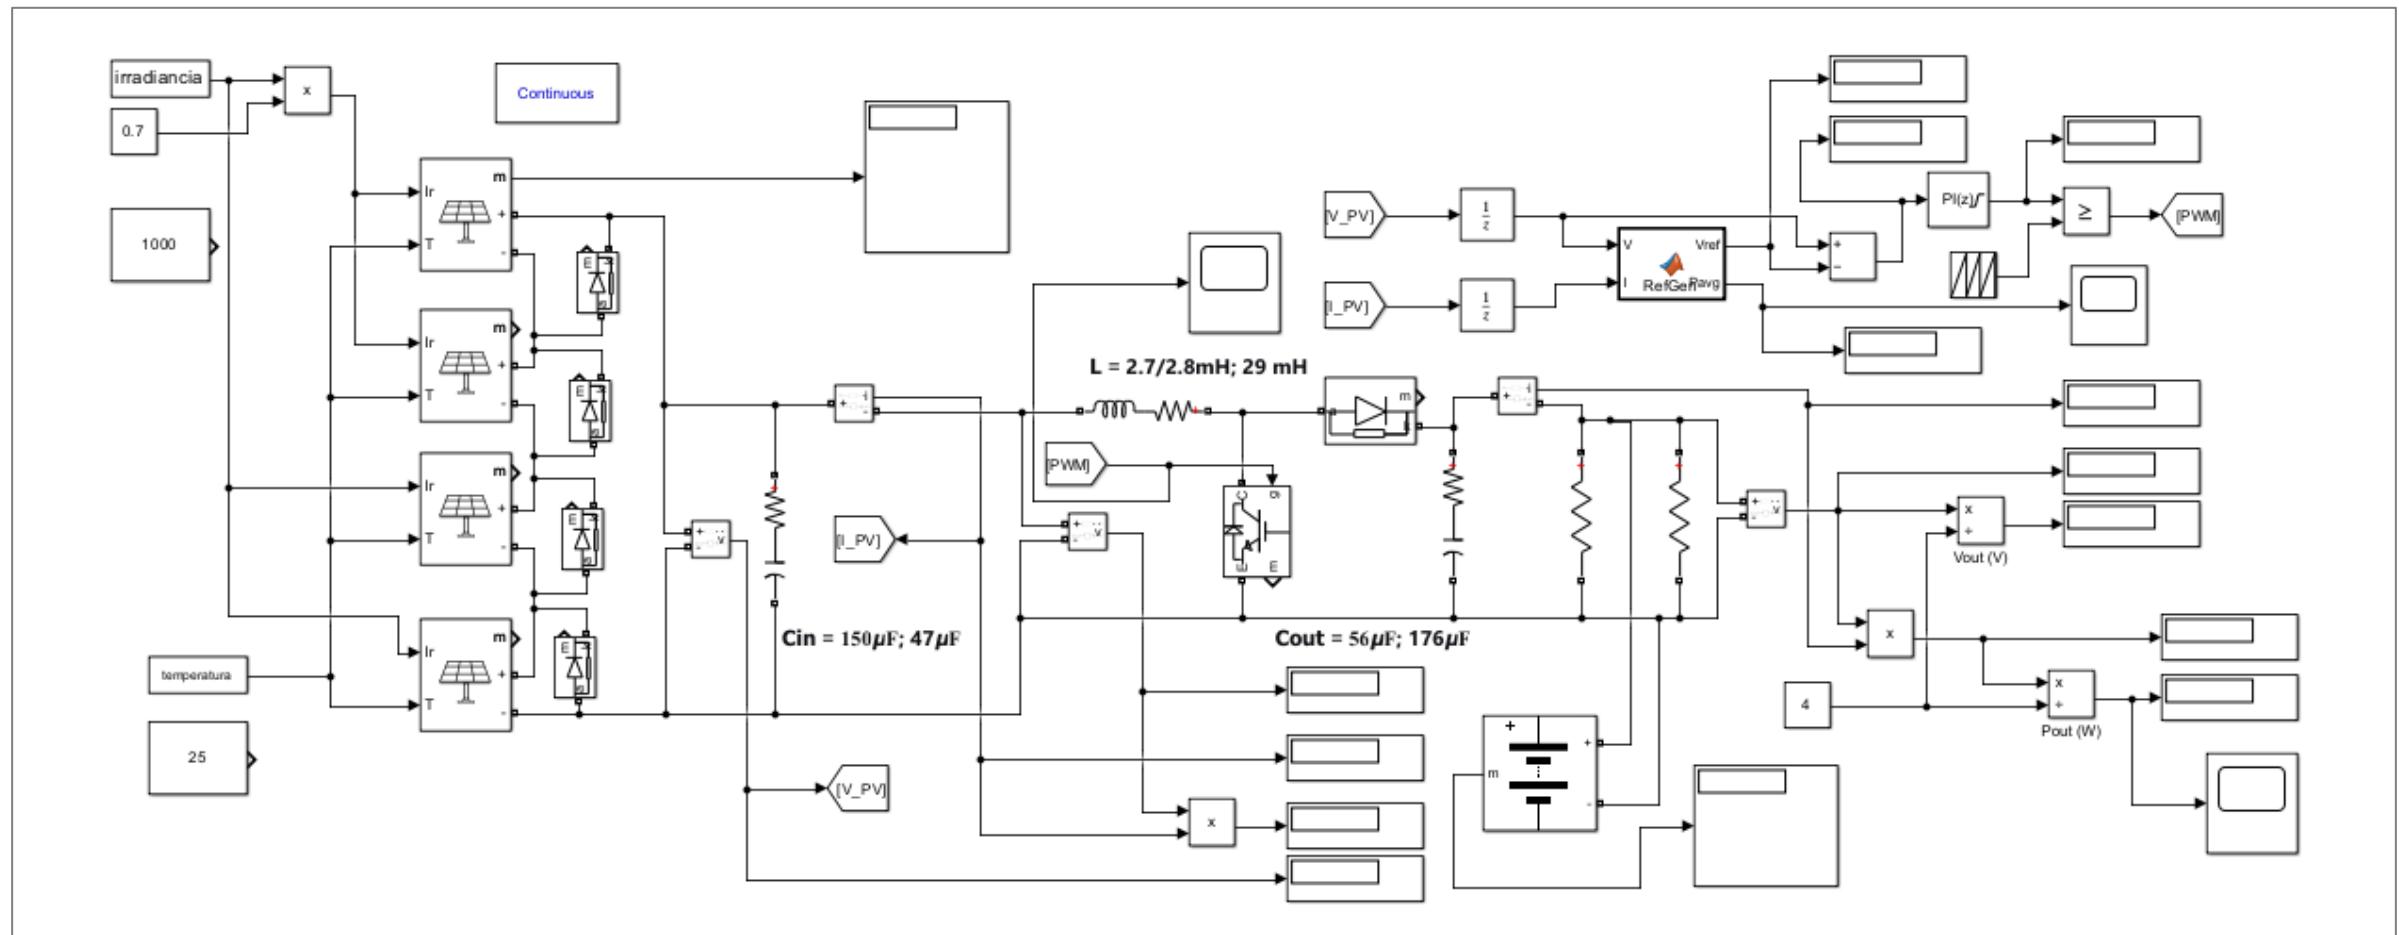
Fonte: Autor

Dados de irradiância e temperatura.



6. Resultados Parciais e Esperados

6.3 Desenvolvimento do modelo digital do sistema no MATLAB/Simulink



Fonte: Autor

Digital Model.

- 1. Geração de dados Sintético Rotulados:** uso do modelo digital para criar milhares de amostras V, I, P sob cenários normal e PSC. Inclusão de variação de G, T, perfis dinâmicos e níveis de sombreamento.
- 2. Treino e Validação do Modelo Random Forest:** Treino com divisão estratificada (70/15/15). Otimização via **validação cruzada k=5**. Métrica alvo: **F1-Score macro**. Resultando num modelo preciso na classificação PSC.

3. Validação Experimental do RF no Sistema Real

Testes físicos com PSC controlado (0%, 25%, 50%, 75%). Comparação entre predição (RF) e condição real medida. Demonstração da transferibilidade sintético → real.

- 4. Embarcar o modelo RF no (ESP32):** Conversão do SDM e do modelo RF treinado para C/C++ otimizado. Integração completa no ESP32: Leitura dos sensores (V, I, G, T). Cálculo da potência esperada pelo SDM no *próprio chip*. Comparação $P_{real} \times P_{SDM}$. **Inferência local**.

5. Ter o Gêmeo Digital Híbrido operacional

GDH funcionando em tempo real, com:

Núcleo físico SDM validado;

Classificador leve e embarcado;

Comunicação com a nuvem (dados históricos → retreinamento).



7. Contribuições e limitações da proposta

O GDH resultante, é denominado A0 e é um DT propriamente dito com capacidade de detectar falhas em tempo real, mas tem suas limitações.

Contribuições	Limitações
<ul style="list-style-type: none">➤ Uma ferramenta para gestão e manutenção inteligente de pequenos SFVs;➤ Detecção e diagnóstico em tempo real de PSC;➤ Uma metodologia de geração de dados elétricos sintéticos para treinar modelos de ML menos complexos;➤ Dataset público de dados elétricos rotulados de PSC e operação normal;➤ Dataset público de dados ambientais de irradiância e temperatura;➤ Inferência local (diagnóstico rápido)➤ Arquitetura preparada para aprendizagem contínua.	<ul style="list-style-type: none">➤ Dependência de infraestrutura especializada para o desenvolvimento do GDH;➤ Dependência de sensores físicos;➤ Falta de capacidade de prognóstico;➤ Inviável para sistemas de grande porte devido a complexidade da modelagem e capacidade do hardware;



A1 - Diagnóstico Físico Informado

- Usar o A0 como base;
- **Introduzir de sensores virtuais** para estimar variáveis internas não medidas (ex.: Tc, irradiação efetiva);
- **Calcular resíduo físico** (diferença entre o real e o comportamento previsto).
- **Combinar sensores reais + sensores virtuais + SDM + ML**, aumentando robustez e interpretabilidade;
- Detetar **anomalias com base em consistência física**, e não apenas em padrões estatísticos (como no A0).



A2 - Sincronização e Prognóstico

- **Introduzir modelo de ML com memória (temporal) capaz de prever cenários futuros;**
- Utilizar Filtro de Kalman Estendido (EKF) para sincronização recursiva entre o ativo físico e o modelo digital;
- **Fornecer prognóstico leve, antecipando tendências de degradação;**
- Tornar o GDH preditivo e auto-adaptativo, evoluindo além do diagnóstico local do A0.



9. Resultados Esperados da Proposta Estendida

9.1 Resultados esperados A1/A2

Espera-se que o A2 seja uma versão melhorada do A0, com menos instrumentação e que tanha capacidade de prever eventos como tendências de degradação por exemplo.



10.1 Atividades

1. Geração de dados sintéticos; treino e otimização e validação do modelo de ML *Random Forest*;
2. Implementação do modelo no ESP32; desenvolvimento do firmware; validação em bancada com sombreamento controlado;
3. Implementação da integração com a cloud e do ciclo OTA; validação de longa duração em ambiente real; redação final da tese e submissão do artigo.
4. Desenvolvimento, implementação e validação experimental da variante estendida A1
5. Desenvolvimento, implementação e validação experimental da variante estendida A2

Atividades	Tempo em anos						
	2025	2026					
	Tempo em meses						
Atividades	Dezembro	Janeiro	Fevereiro	Março	Abril	<th>Junho</th>	Junho
1							
2							
3							
4							
5							

11. Entregáveis

Um artigo sobre a modelagem e validação experimental do módulo fotovoltaico submetido, aceite e apresentado na ***International Conference on Sustainable Energy, Smart Cities, and Business Intelligence (ICSSB 2025)***. O evento realizou-se nos dias 29 e 30 de agosto de 2025, no Annacis Research and Event Centre, em Delta, **Vancouver, BC, Canadá**. Os artigos aceites e apresentados serão publicados em proceedings **indexados na Scopus**.

!!!!



13. Conclusões

Os resultados alcançados até ao momento demonstram que o desenvolvimento do Gêmeo Digital Híbrido A0 avança de forma consistente. O módulo fotovoltaico foi modelado e validado experimentalmente com boa precisão, estabelecendo um núcleo físico confiável para o gêmeo digital.

O **modelo completo** no MATLAB/Simulink **está operacional** e apto para gerar dados sintéticos realistas para suporte ao treinamento do modelo de ML.

O **pipeline de dados e aprendizado de máquina está estruturado**, e o sistema experimental de aquisição de dados de irradiância e temperatura já se encontra funcional.

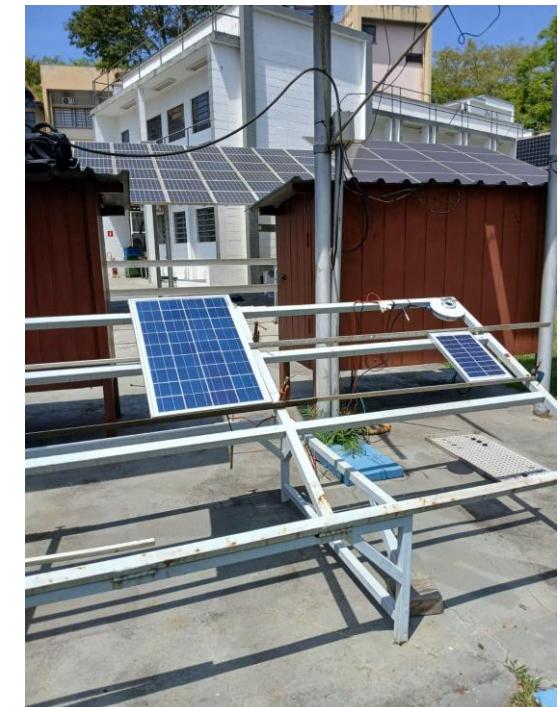
A arquitetura geral do A0, baseada no SDM embarcado, leitura de sensores reais, comparação físico-digital e inferência local via Random Forest, está definida e tecnicamente fundamentada, embora ainda em implementação.

Reconhece-se que o A0 permanece em desenvolvimento, especialmente na portabilidade do SDM e do RF para o ESP32 e na integração final dos componentes.

Suas limitações atuais, como a ausência de sensores virtuais e de sincronização recursiva, justificam as variantes A1 e A2.

12. Agradecimentos

- Ao Instituto de Energia e Ambiente da Universidade de São Paulo (IEE-USP), especialmente à Área de Energia Fotovoltaica, pela disponibilização da infraestrutura, equipamentos e suporte técnico necessários à caracterização experimental do módulo, à coleta de dados e à implementação do sistema.



- Ao Projeto de Desenvolvimento de Ciência e Tecnologia de Angola PDCT, e ao Ministério do Ensino Superior, Ciência, Tecnologia e Inovação de Angola MESCTI pela bolsa de estudo.



Meu sincero reconhecimento às instituições que sustentam esta pesquisa.!

Muito Obrigado!